Lab 02: Deep Reinforcement Learning

Junyeong Park

Today's Topic

- Application of Neural Network in RL
- Q-Learning with NN
- Policy Gradient

The limits of Q-Learning

Q-Learning은 테이블 형식의 강화학습이다.

- FrozenLake에서 전체 상태의 개수는 16개였다.
- 에이전트가 선택할 수 있는 행동은 4개였다.

→ 총 $16 \times 4 = 64$칸의 테이블로 큐함수를 표현할 수 있다.

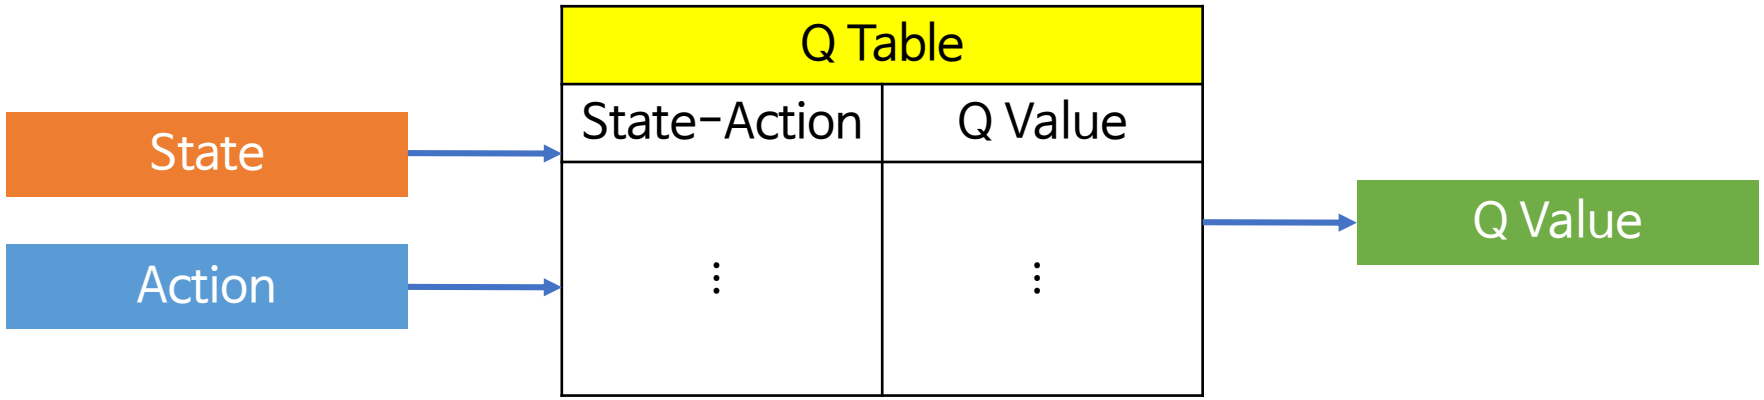

The limits of Q-Learning

하지만 우리가 풀고자 하는 문제들은 단순하지 않다.

→ 테이블 형식으로 풀기는 힘들다.

Approximation Function

- 강화학습도 결국 함수를 만드는 과정이다.
- 표현하기 복잡한 함수를 근사할 수 있다.

→ 신경망을 통해 함수를 근사할 수 있다.

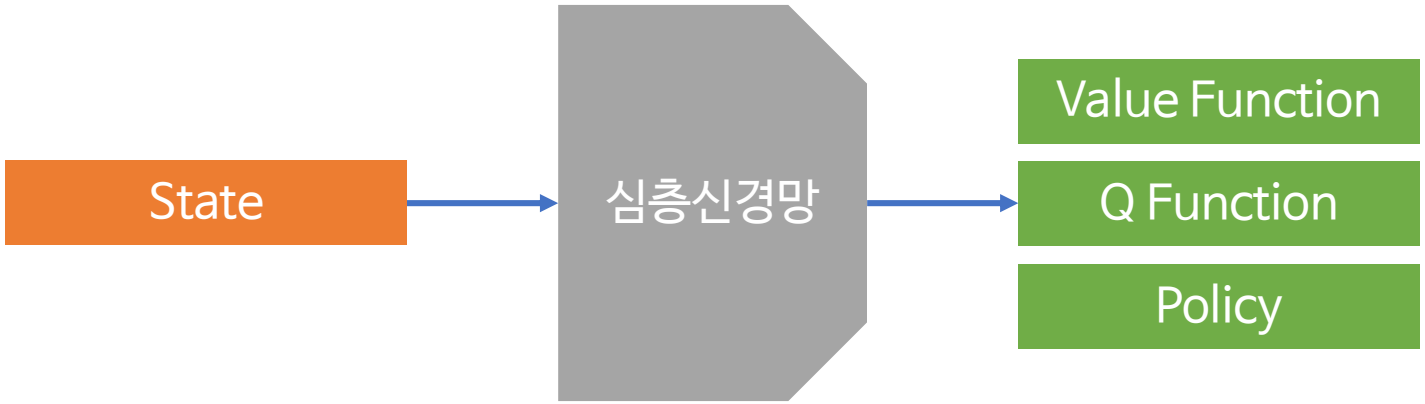

CartPole-v0

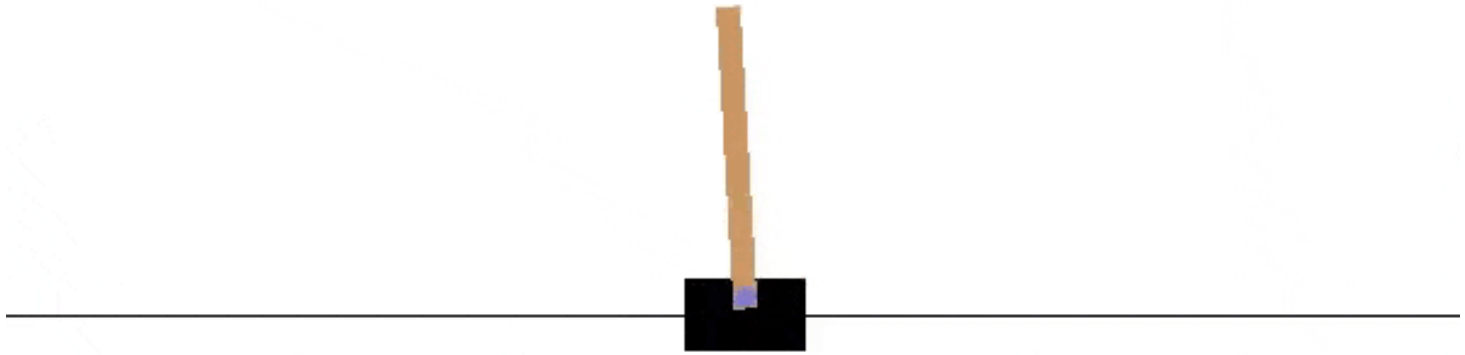

- 검은색 카트를 움직여 막대가 떨어지지 않도록 하는 것이 목표.
- 카트가 움직이지 않으면 중력에 의해 막대가 아래로 늘어뜨려진다.

CartPole-v0

- Observation : $[x, \theta, dx/dt, d\theta/dt\ ]$
  - x : 트랙 상에서 카트의 위치
  - θ : 막대와 수직선이 이루는 각도
  - dx/dt : 카트의 속도
  - $d\theta/dt$: 막대의 각속도

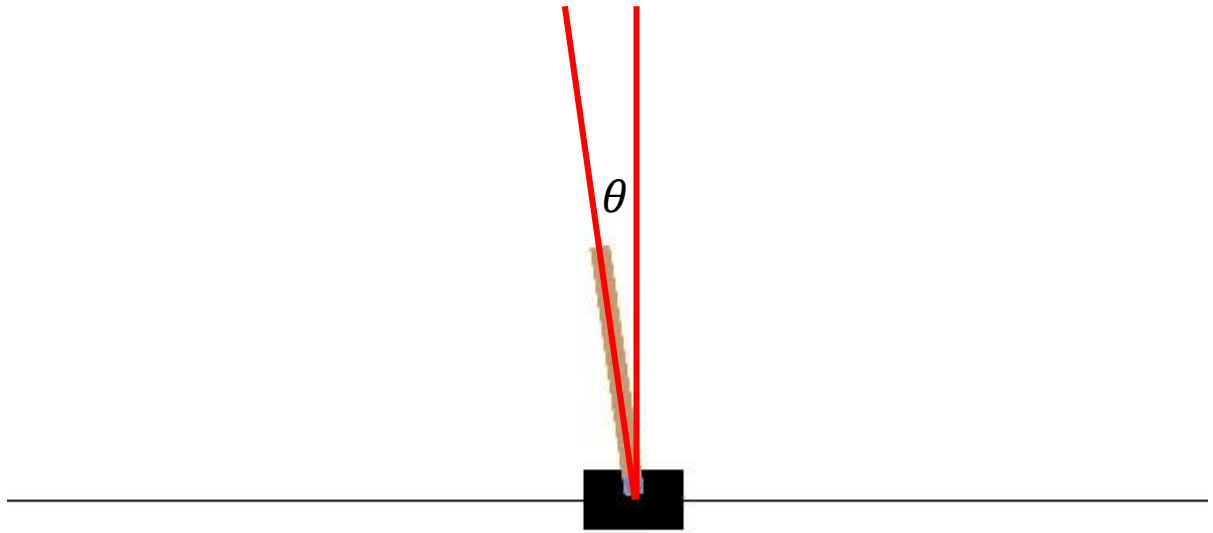

CartPole-v0

- 종료 조건
  - θ가 $15°$ 이상
  - 원점으로부터의 거리가 2.4 units 이상
- Action : 좌우로 이동 (0 or 1)
- Reward : 에피소드가 유지된 시간

CartPole-v0

- FrozenLake와는 다르게 observation이 연속적인 값이다.
- State-Action 쌍의 개수가 무한히 많다.
- 테이블 방식으로 풀기는 어렵다.

→ 신경망으로 큐 함수를 근사하자!

Network Architecture

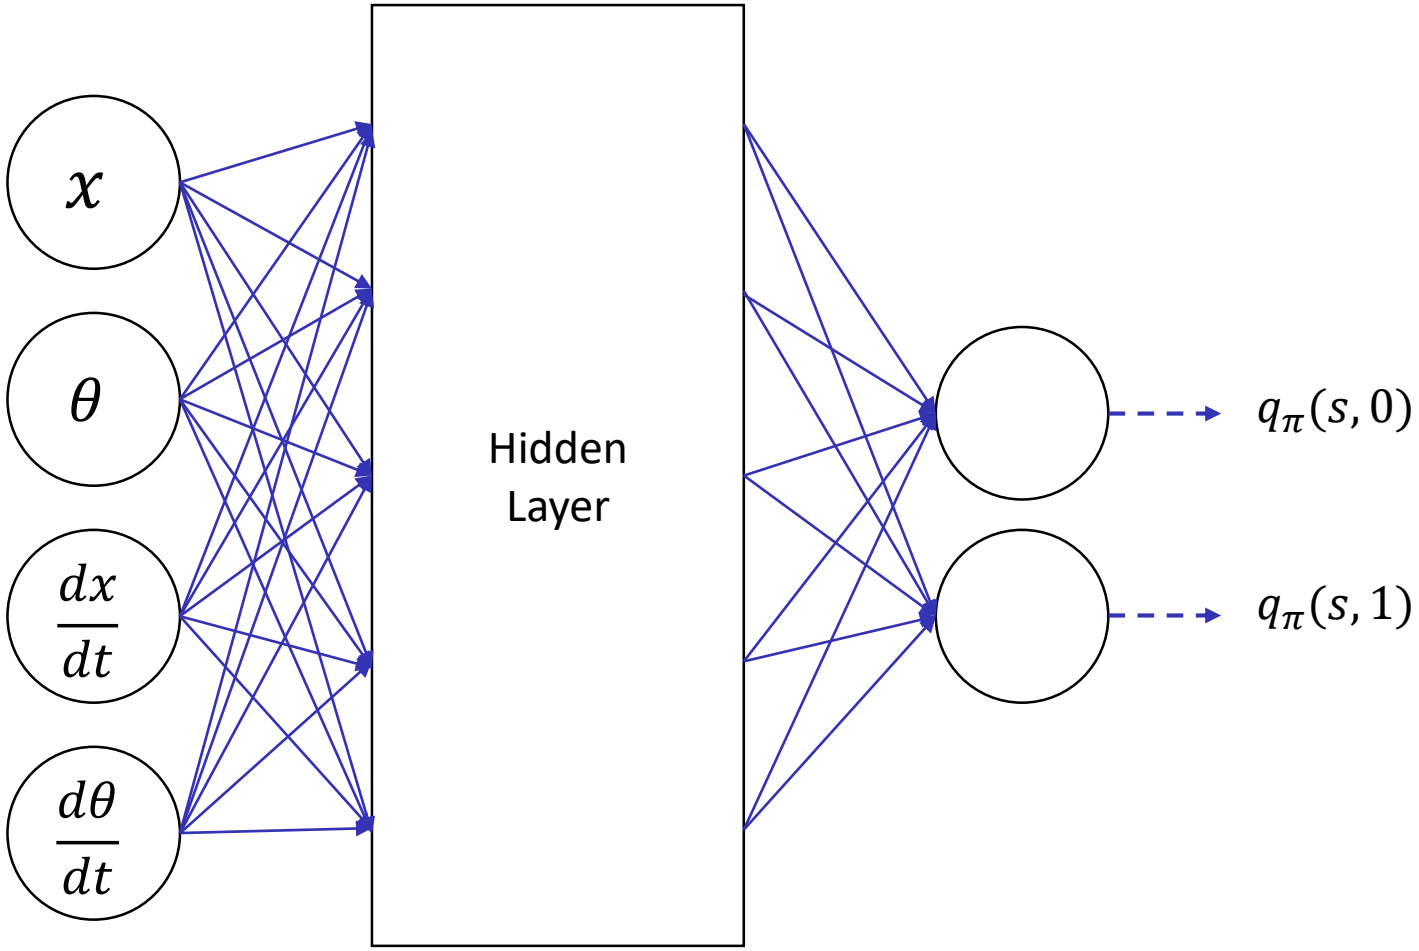

Optimization

지난 시간 살펴본 Q-Learning 수식은 다음과 같다.

$$Q(s,a) \leftarrow Q(s,a) + \alpha[\underline{R_{t+1} + \gamma \max Q(s',a')} - Q(s,a)]$$

학습의 목표

- MSE(Mean Square Error)를 통해 신경망을 학습시킬 수 있다.

→ $L = \left(R_{t+1} + \gamma \max Q(s',a') - Q(s,a)\right)^2$

Practice

Google Colab 링크

http://bitly.kr/uzYg0zHf

Policy-based Reinforcement Learning

지금까지의 강화학습 알고리즘은 가치 함수를 바탕으로 동작
→ 가치 기반 강화학습(Value-based Reinforcement Learning)

정책을 기반으로 한 강화학습 알고리즘도 생각해볼 수 있다.
→ 정책 기반 강화학습(Policy-based Reinforcement Learning)

Policy-based Reinforcement Learning

- 상태에 따라 바로 행동을 선택한다
  → 가치함수를 토대로 행동을 선택하지 않는다.
- 정책을 직접적으로 근사한다.

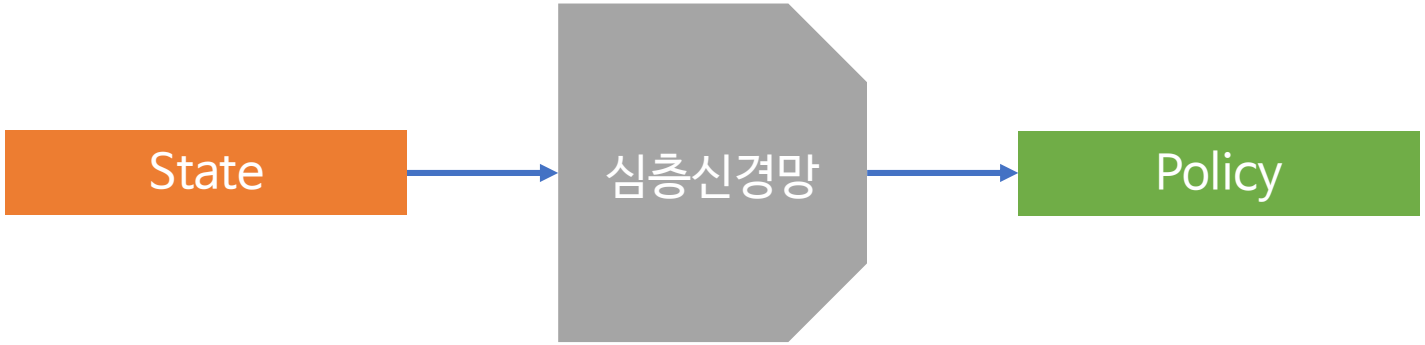

- 신경망으로 정책을 근사하고, 신경망의 출력은 정책이 된다.

Advantages and Disadvantages

- 장점
  - value-based 방식보다 수렴이 더 잘 된다.
  - 가능한 action이 여러 개이거나 action이 연속적인 경우에도 효과적이다.
  - 확률적인 정책을 배울 수 있다. (ex 가위바위보)

- 단점
  - local optimum에 빠질 수 있다.
  - policy를 평가하는 게 비효율적이다. (반환값을 계산 해야한다)
  - variance가 높다.

Policy-based Reinforcement Learning

신경망으로 근사된 정책은 다음과 같이 표현할 수 있다.

$$\pi_\theta(a|s)$$

- θ는 정책 신경망의 가중치다.
- 목표함수는 $J(\theta)$로 표현할 수 있다.
- 정책을 근사하는 신경망의 출력층은 Softmax를 사용한다.
  → 가장 최적의 행동을 선택하는 분류 문제로 생각할 수 있다.

Policy Gradient

강화학습의 목표는 누적 보상을 최대로 하는 최적 정책을 찾는 것이다.

따라서 정책 기반 강화학습의 목표를 수식으로 표현하면 다음과 같다.

$$\text{Maximize } J(\theta)$$

목표함수 $J(\theta)$의 최대화는 미분을 통해 미분한 값에 따라 업데이트 하면 된다.

→ 일반적인 경사하강법의 반대로 "경사상승법"이라고 한다.

Policy Gradient

미분을 통해 정책 신경망을 업데이트 해보자.

어느 시간 t에서 신경망의 가중치 θ_t에서 다음과 같이 θ_{t+1}을 구할 수 있다.

$$\theta_{t+1} = \theta_t + \alpha \nabla_\theta J(\theta)$$

목표함수는 $J(\theta) = v_\pi(s)$이므로 목표함수의 미분은 다음과 같다.

$$\nabla_\theta J(\theta) = \nabla_\theta v_\pi(s)$$

Policy Gradient

가치함수의 정의를 이용하면 최종적으로 가중치의 업데이트 식은 다음과 같다.

$$\theta_{t+1} = \theta_t + \alpha[\nabla_\theta \log \pi_\theta(a|s) q_\pi(s,a)]$$

하지만 에이전트에 가치함수나 큐 함수가 없기 때문에 $q_\pi(s,a)$를 구할 수 없다.

REINFORCE

가치함수는 반환값(Return)의 기댓값이다.

→ 큐 함수를 반환값 G_t로 대체할 수 있다. 이를 REINFORCE 알고리즘이라 한다.

REINFORCE 알고리즘의 업데이트 식은 다음과 같다.

$$\theta_{t+1} = \theta_t + \alpha[\nabla_\theta \log \pi_\theta(a|s)\, G_t]$$

- $\log \pi_\theta(a|s)$는 실제로 한 행동을 정답으로 둔 것이다.
- 하지만 잘못된 선택을 할 수 있어 반환값을 곱해준다.
  → 부정적인 보상을 받게 된다면 그 행동을 선택할 확률을 낮춘다.

Practice

Google Colab 링크

http://bitly.kr/u99edFOF

Combination Policy-based with Value-based

- REINFORCE의 단점

: 에피소드가 끝나야 업데이트가 가능하다.

하지만 $q_\pi(s, a)$를 알 수 있다면 매 time-step마다 업데이트가 가능하다.

→ Critic을 만들자! (Actor Critic 알고리즘)

Combination Policy-based with Value-based

AlphaGo도 Actor Critic의 영향을 받았다.